



ISS Projekt 2020/2021

Protokol

Datum: 02.01.2021

Autor: Roman Popelka(xpopel24)

Tabulka tónů (Úkol č. 1)

- Na tabulce níže, jsou názvy nahrávek tónů a jejich délky v sekundách a vzorcích. Nahrávky jsou již přeformátované v předovězaném stavu na délce kolem 1s, přesně se ořezávají až v programu

Název nahrávky	Délka nahrávky [sekundy]	Délka nahrávky [vzorky]
maskoff_tone.wav	1.144187	18307
maskon_tone.wav	1.300312	20805

Tabulka vět (Úkol č.2)

- Na tabulce níže, jsou názvy nahrávek vět a jejich délky v sekundách a vzorcích.


Název nahrávky	Délka nahrávky [sekundy]	Délka nahrávky [vzorky]
maskoff_sentence.wav	1.763875	28222
maskon_sentence.wav	2.170562	34729

Úkol č.3

- V této části jsem nejprve ořezal všechny nahrávky na přesně 16000 vzorků, tedy 1 s. Potom jsem je ustřednil pomocí knihovní funkce numpy mean, ustředněné data jsem pak normalizoval do rozsahu [-1,1] za použití knihovních funkcí numpy abs a max.
- Jako další jsem úseky rozdělil na rámce o délce 20 ms překrývající se o 10 ms. Rozhodl jsem se zvolit variantu s kratší nahrávkou a tedy 99 rámci.
- Jako vzorec pro výpočet velikost rámce ve vzorcích jsem použil:

$$velikost\ rámce = Fs * 0,02,$$
 kde Fs zastupuje vzorkovací frekvenci a koeficient zastupuje část, kterou tvoří 20ms v sekundě. Při vzorkovací frekvenci 16000 Hz a délce rámce 20ms, plyne, že velikost rámce bude 320 vzorků

- Grafy rámců



Kontrola rozdílu výšky tónu (Úkol č.4)

Clipping

- Jako první metodu jsem aplikoval 70% clipping na všechny rámce tónů s rouškou a bez roušky. Jako maximální hodnotu při clippov

Autokorelace

- Další funkce, kterou jsem aplikoval na rámce tónů, byla autokorelace, která se používá pro porovnání signálu se sebou samotným. Extrahoval jsem z ní lags, které jsem pak použil pro zjištění základní frekvence tónů
- Jako práh jsem u autokorelace použil 500Hz, což je 32. vzorek
- Pro vlastní implementaci jsem použil vzorec pro vychýlený odhad autokorelačních koeficientů

Základní frekvence tónů

Po aplikaci autokorelace na rámce jsem z každého rámce tónů s rouškou a bez roušky pomocí knihovny funkce numpy - argmax zjistil lagy, potřebné pro zjištění základní frekvence.


Následně jsem vypočítal základní frekvenci pomocí vzorce $f_0 = f_s / \text{lag}$

Střední hodnota a rozptyl nahrávek

Název nahrávky	Střední hodnota	Rozptyl
maskoff_tone.wav	126.77521906942714	3.1750938203260257
maskon_tone.wav	127.90234820215142	0.7294824439322417

Odpověď na otázku ze zadání

Grafy



DFT (Úkol č.5)

Postup

První krok, který jsem udělal, byla aplikace DFT s $N = 1024$ nad ustředněnými a normalizovanými rámci tónů s rouškou a bez roušky.

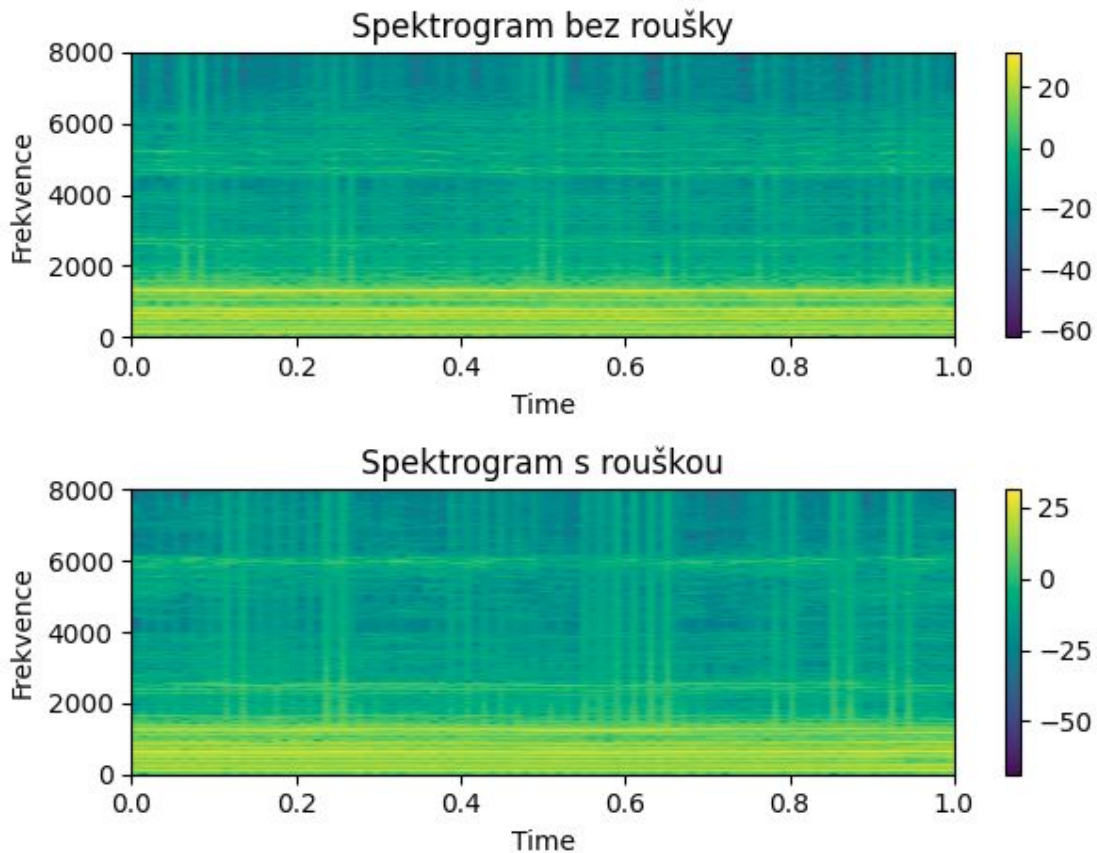
Poté jsem upravil výsledné hodnoty pomocí vzorce $P[k] = 10 \log_{10}|X[k]|^2$.

Nakonec jsem vykreslil spektrogramy.

Vlastní implementace DFT

```
def DFT(frame):  
    dft = list()  
    frame_in = list()  
    frame_in.extend(frame) #Překopírování rámce  
    frame_in.extend([0]*(1024-len(frame))) #Rozšíření rámce  
    for k in range(len(frame_in)):  
        sum_of = complex()  
        for n in range(len(frame_in)):  
            sum_of += frame_in[n]*cmath.exp(-2j*cmath.pi*n*k/1024)  
        dft.append(sum_of)  
    return dft
```

Spektrogramy



Frekvenční charakteristika roušky (Úkol č.6)

Postup

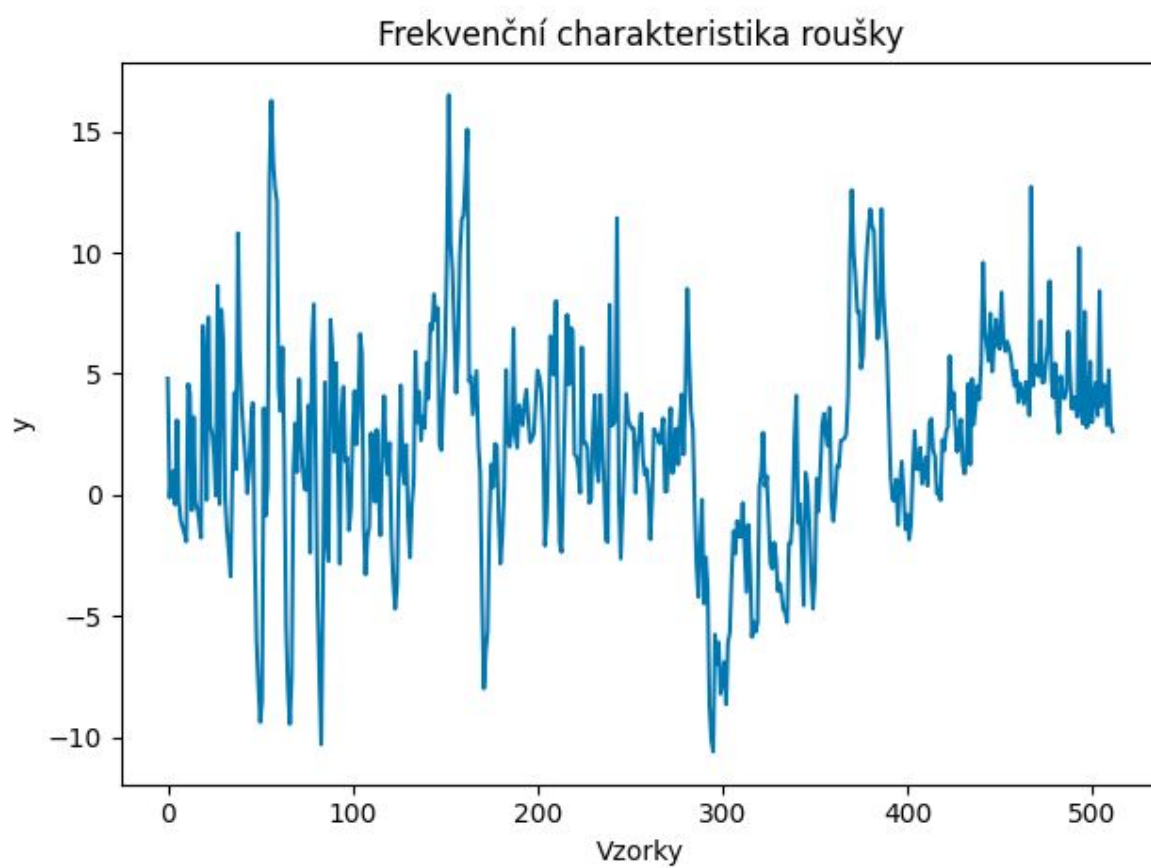
Nejprve jsem použil vzorec pro $H(e^{j\omega})$ roušky popsaný níže v tom jsem si pomohl knihovni funkce `numpy - divide`, pak jsem zprůměroval všechny rámce pomocí knihovni funkce `numpy - mean` (s parametrem `axis = 0`), po zprůměrování mi zbylo pole o 1024 prvcích s frekvenční charakteristikou. Nakonec jsem všechny hodnoty upravil tak, aby jsem mohl graf vykreslit jako výkonové spektrum.

Vzorec pro výpočet $H(e^{j\omega})$

$$H(e^{j\omega}) = \text{DFT s rouškou} / \text{DFT bez roušky}$$

Pro získání $H(e^{j\omega})$ musíme vydělit všechny prvky rámců po aplikování DFT

Frekvenční charakteristika



Komentář k filtru

filtr zeslabuje signál (ve většině případů)

Impulsní odezva, IDFT (Úkol č.7)

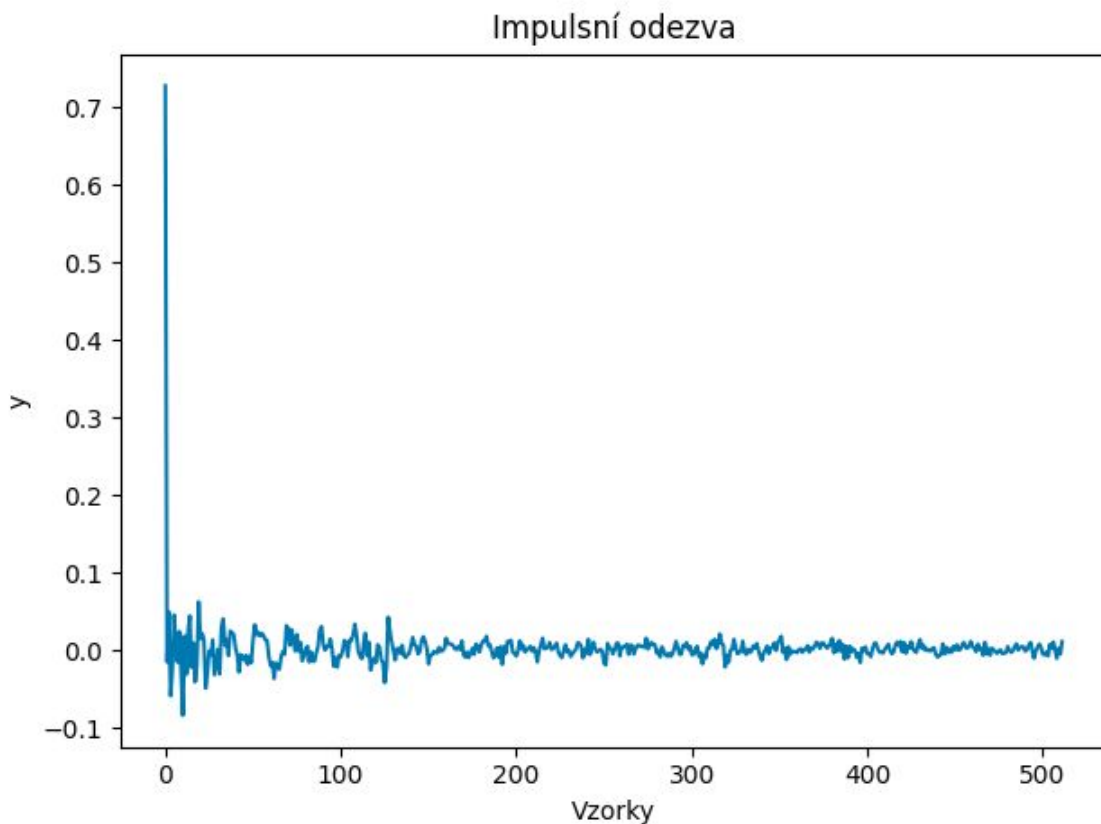
Postup

Na frekvenční charakteristiku jsem aplikoval IDTF s $N = 1024$, tím jsem získal impulsní odezvu

Vlastní implementace

```
def IDFT(frame):  
    idft = list()  
    frame_in = list()  
    frame_in.extend(frame)  
    frame_in.extend([0]*(1024-len(frame)))  
    for n in range(len(frame)):  
        sum_of = 0  
        for k in range(len(frame)):  
            sum_of += frame[k]*cmath.exp(2j*cmath.pi*n*k/1024)  
        frame_in.append(sum_of/1024)  
    return idft
```

Graf Impulsní odezvy

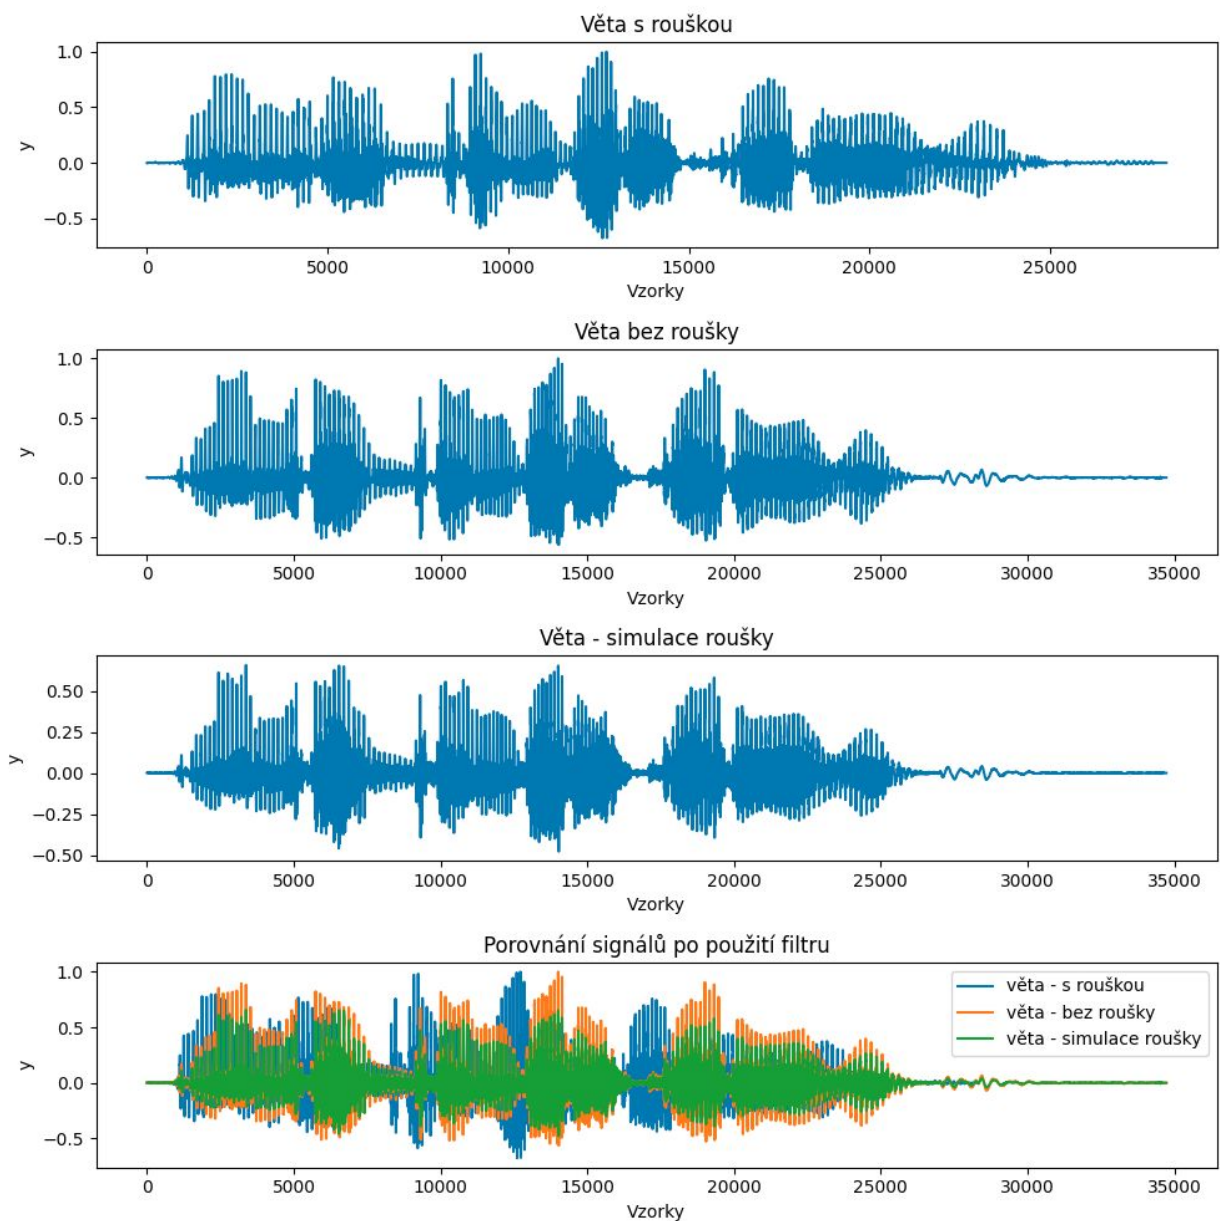


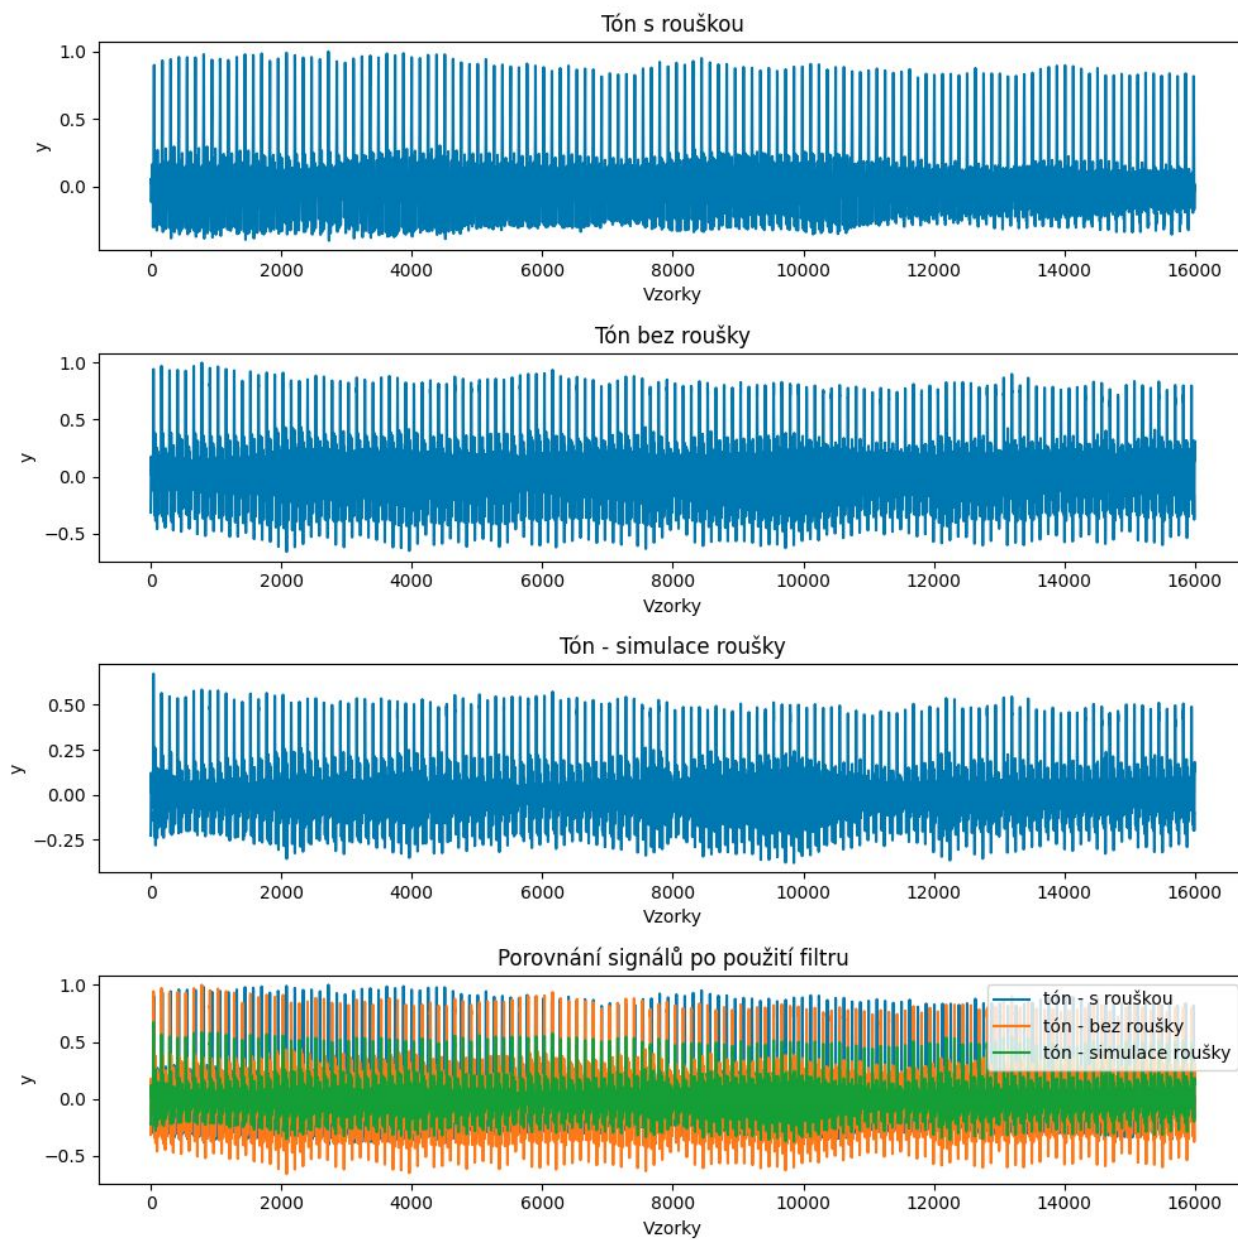
Filtrace nahrávek (Úkol č.8)

Postup

pro vytvoření filtru jsem použil funkci knihovny scipy - lfilter, kde jsem jako parametr filtru zadal impulzní odezvu. Poté jsem vy

Graf





Odpovědi na otázky

- Jak se od sebe liší signály s rouškou a se simulovanou rouškou?
 - Simulovaná rouška má menší amplitudu a více “zubů” v signále
- Jsou signály podobné?
 - Dalo by se říct, že ano. Použití filtru vedlo k zeslabení signálů, lehkému vyhlazení výraznějších “zubů”, či ostrých hran signál simulované roušky, ale pořád úplně nedosahuje takové kvality jako signál bez roušky
- Kde se nejvíce podobají a kde se liší?
 - Nejvíce se podobají ve špičkách signálu (při vyšší amplitudě), kde filtr dokázal vyhladit “zuby” v signálu a částečně se mu podařilo signál zaoblit. Méně se podobají při vyšších amplitudách

Závěr (Úkol č.9)

Filtr snižuje vyšší amplitudy a přijde mi, že při nižších amplitudách zvyšuje frekvenci filtrovaného signálu. Zároveň se filtr snaží částečně vyhlazovat větší ostré hrany. Zvuk tedy zní o něco utlumeněji. Změna signálu sice není nějak výrazná, ale částečně poznat jde. Filtr by byl možná o něco lepší, kdyby byly základní frekvence tónů více podobné. Věty také nebyly úplně stejné, ale z mého výběru byly asi nejlepší. Výsledky hodnotím víceméně kladně.